Pocket TTS に日本語を教える: 1 億パラメータのモデルをそのまま使える形にする学習データと蒸留

Claude（Anthropic）* 森琢磨

テクニカルレポート、2026 年 10 月
https://github.com/takuma104/pocket-tts-ja

概要

Pocket TTS は Kyutai による 1 億パラメータの音声合成（TTS）モデルで、ノート PC の CPU で実時間より速く動く。因果的なトランスフォーマーが Mimi コーデックの連続値の潜在表現を予測し、小さなフローヘッドが 80 ms ごとのフレームを 1 ステップで生成する。本稿ではこれを、厳しい制約のもとで日本語に対応させる。公式の `pocket-tts` パッケージに設定ファイルだけで読み込め、読みの前処理なしに漢字かな交じりの文を読み、ゼロショットの声のクローンを保つこと。作業の大半は学習データだった。Web の音声（Emilia、YODAS3）を ASR の再チェックで選別し、句読点を復元し、話者ごとにゲインを変えた複製で音量を合わせ、まれな漢字の読みを、ASR で読みを確かめた 0.4–0.8 千時間の合成音声で補った。読みの正答率は、その読みが学習に現れる回数に従い、頭打ちを破ったのはステップ数ではなく、毎回新しい合成データだった。公式の実行系は発話終了（EOS）の判定の後にも数フレームを生成するが、上流の学習はそこを教えていない。そこをデジタル無音で教えると、約 10% の文の後のフィラーが消えた。ガイダンスは重みに蒸留し、6 層の生徒は 24 層の教師より正しく読む。最後に、コーデックのデコーダだけを微調整し、潜在表現と声のプロンプトの互換性を保つ。JKYB-Parakeet の 13,536 文で、公開した 6 層のモデルは対象語の 94.75%（Emilia も使った版、CC BY-NC）と 94.77%（CC BY のデータだけの版）を正しく読む。

1 はじめに

Pocket TTS [1] は、Kyutai が 2026 年に公開した小さな TTS モデルで、連続値の音声言語モデル（CALM）[2] に基づく。約 1 億パラメータで、約 200 ms の遅延でストリーミングし、ノート PC の CPU 2 コアで実時間の約 6 倍の速さで動き、数秒の音声から声をクローンする。新しい言語へのレシピを含む学習コードも公開されている。公式のモデルは英語と欧州の 6 言語で、日本語はない。

日本語はこのモデルにとって難しい。文に空白がなく、漢字の多くは語と文脈で決まる複数の読みを持つ。生は「生活」では *sei*、「生ビール」では *nama*、「生きる」では *i* と読む。Pocket TTS にはテキストエンコーダも辞書もない。トークナイザのピースを埋め込み表で引くだけで、読みはすべてトランスフォーマーが音声とテキストの対から学ぶ必要があり、まれな読みはそこに数回しか現れない。

目標は次の 4 つとした。(i) 公式パッケージ（3.3.0）が `--config` で、コードの変更なしに読み込む。(ii) 漢字かな交じりの文をそのまま読む。(iii) 6 層のモデルが CPU で動く。(iv) 非商用の Emilia コーパスを使う系統（以降、本線と呼ぶ）に加えて、CC BY のデータだけで学習する系統（CC BY 版）を作り、そのウェイトを商用でも使えるようにする。以下、学習データ（3 節）、学習のレシピと発話の終わりの教え方（4 節）、蒸留（5 節）、デコーダ（6 節）、公開したモデル（7 節）を述べる。モデルは Hugging Face で公開している[1]。

2 Pocket TTS

FlowLM。因果的なトランスフォーマー（6 層または 24 層、幅 1024、16 ヘッド）が、条件を読んでから目標の潜在表現をフレームごとに読む。その出力を条件に、フローヘッド（適応的レイヤ正規化付きの MLP、6 ブロック、幅 512）[3] が次の潜在表現を生成する。フローヘッドは一貫性モデル系の目的関数である Lagrangian self-distillation（LSD）[4] で学習され、推論は 1 ステップ $x_1 = x_0 + v(0, 1, x_0)$（$x_0 \sim \mathcal{N}(0, \tau)$、温度 $\tau = 0.3$）で済む。トランスフォーマーの出力にある線形のヘッドが発話の終わり（EOS）を予測する。系列は、学習されたトークン、声のプロンプト（参照音声の Mimi 潜在表現を射影したもの）、テキスト（ピースごとの埋め込み）、BOS の潜在表現、目標の順である。学習ではテキストと声の条件をそれぞれ 20% の確率で落とし、トランスフォーマーの出力で classifier-free guidance（CFG）[5] をかけられるようにしている。

Mimi は Moshi [6] のコーデックで、24 kHz の音声を 12.5 Hz、32 次元の連続値の潜在表現に符号化する。畳み込みの SEANet エンコーダ・デコーダ（ストライド 6, 5, 4）と小さなトランスフォーマーからなる。Mimi は凍結され、どの言語のリリースでも同じ重みである（表 1）。

*Claude（Opus 5.5）が Claude Code 上で、データパイプラインと実験の計画と実装、実行、結果の分析、本稿の執筆を行った。6 節のデコーダの微調整は、別の Claude Code のセッションが行った。森琢磨は、目標（公式の `pocket-tts` パッケージが変更なしで読み込める日本語モデル、CC BY のデータだけで学習する 2 本目の系統）を定め、データの出典とライセンスを選び、計算機を用意し、試聴（短い文の後の余計な発話を見つけ、デコーダを選んだ）と公開の判断を行った。

[1] https://huggingface.co/takuma104/pocket-tts-ja（CC BY-NC 4.0）と https://huggingface.co/takuma104/pocket-tts-ja-cc（CC BY 4.0）。

表 1　Pocket TTS の構成（6 層 / 24 層のモデル）と本稿で学習する部分（* 蒸留の間は凍結）。

部分	パラメータ	本稿
トランスフォーマー（幅 1024）	75.5M / 302.1M	学習
テキストの埋め込み（4,000）	4.1M	新規
フローヘッド、EOS ヘッド	9.8M	学習 *
Mimi のエンコーダ側	9.8M	凍結
Mimi のデコーダ側	10.3M	微調整
合計	109.5M / 336.1M	

公式の実行系が固定しているもの。設定ファイルで変えられるのは、重み、モデルの大きさ、SentencePiece のトークナイザ、温度、文字の置換、EOS の後に生成するフレーム数である。残りは固定されている。CFG はない。テキストは文、次に節の句読点で、最大 50 トークンのチャンクに切られる。生成は トークン数/3 + 2 秒で打ち切られる。トークナイザは正規化をしない。EOS の後には、空白区切りで 4 語以下の入力なら 3（それ以外は 1）に 2 を足した数のフレームを生成する。日本語の文は 1 語と数えられるので 5 フレーム（400 ms）になる。小さな語彙、学習での ASCII の句読点、CFG の蒸留、短いチャンクと EOS の後のフレームへの配慮は、これらの規則のためである。

3　学習データ

3.1　自然音声

Emilia [7, 8] の日本語は、1,716 時間（Emilia、CC BY-NC）と 1,120 時間（Emilia-YODAS、CC BY）の 3–30 秒のクリップである。Emilia の 3 シャードは 95% が Emilia-YODAS と同一で、残りも 21% が重複（再投稿された聴解問題、チャンネルの締めの挨拶）だった。話者ラベルは 1 本の動画の中の 1 人の話者で（ECAPA [9] の類似度はラベル内 0.69–0.73、ラベル間 0.15）、声のプロンプト（目標と同じ話者の別の発話）は同じラベルから取る。重複の除去とフィルタ（1 秒あたり 1.5–15 文字、DNSMOS [10] 3.0 以上、ベンチマークの文を除く、話者あたり 2 発話以上、話者の一貫性）の後に 1,709 時間が残る。

YODAS3 [11, 12]（CC BY 3.0）は全帯域の日本語の YouTube 音声 17,404 時間で、区切りも話者も品質の指標もなく、字幕は大半が句読点のない自動字幕である。無音で 3–20 秒の発話に切り（Silero VAD [13]）、Whisper [14] で書き起こし、字幕と書き起こしの読みが一致する（フィラーを除いたかな CER 0.10 以下）発話を残す。ラベルは書き起こしとする。話者は動画ごとの ECAPA のクラスタで、ほかの 20 本以上の動画のクラスタと一致するものは量産された TTS の声（試験では全部が Wikipedia の読み上げだった）として除く。8,311 時間の区間のうち 601 時間が残る。ラベルの 72% には句読点がなく（Emilia は 2–7%）、読点なしで間を置くことを教えてしまう。各クリップを句読点付きのプロンプトで書き起こし直し、句読点だけを写すと、句読点のないものは 1.3% になる。

3.2　試聴と ASR で見つかったこと

短い文の後の余計な発話。試聴で、短い文の後の余計な音（…ハチガツデス、ゲツ）が見つかった。15 カナ未満の JKYB の文の 26–44% が 2 カナ以上の余計な発話で終わり、30 カナ以上では 0 だった。Emilia の最短のクリップは 3.04 秒なので、短い書き起こしが長いクリップに入っており（1 秒あたり 2.2 文字、通常は 5.6 文字）、聴いたものの 40% では話者が文を繰り返すか話し続けていた。そこで学習で使う潜在表現そのものをデコードして kana-whisper [15] で書き起こし、フィラーを除いて $\max(3, 0.2n)$ カナ以上の挿入がある（n: 参照のカナ数）、CER が 0.3 を超える、ASR がループする、のいずれかでクリップを除いた。Emilia は 1,531 時間が残り、短い Tatoeba の文（後述の S4）と合わせて、15 カナ未満の文の後の余計な発話は 25.8% から 3.0% に減った。YODAS3 では同じ確認で、15 カナ未満のクリップの半分が落ちた（残り 559 時間）。

音量。小さい声のプロンプトでは出力も小さかった。学習音声は −24 から −14 LUFS、JVS のプロンプトは −24 から −31 で、実行系はプロンプトを正規化しない。Emilia のクリップの 20% を、話者ごとに $[-15, +3]$ dB から選んだゲインで符号化し直し、別の話者として加えた（プロンプトと目標が同じゲインになる。227 時間）。プロンプトとの音量差は −2.2 から −0.9 LU になった。

3.3　読みを補う合成音声

なぜ必要か。Emilia だけでは、教師は JKYB-mini で 70–72% に止まった。正答率は、漢字と読みの組が学習に現れる回数（その組を含む学習文の数）に従う。1–9 文で 32%、10–29 で 54%、30–99 で 83%、100–299 で 89%、それ以上で 95–96% である。対象語をカタカナで書くと 88.1% が 96.2% になる。発音はできるが、漢字から読みへの対応が足りない。

教師とテキスト。合成には Irodori-TTS-v4.1-Small-Yomi [16]（テキストだけの自己蒸留で漢字の読みを改善したモデル。JKYB 95.7%、MIT ライセンス）を使い、声は Emilia から取った 3,000 人分とした。最初の 30 万文（S1）は、その研究の読みを狙った例文（KANJIDIC2 [17]、青空文庫のルビ、LLM の例文）、Emilia にまれな語を含む Wikipedia の文、一般の文からなる。語の選択にベンチマークのキーは一度も使わず、JKYB・JVS・JSUT・青空文庫の評価用作品と重なる文は除いた。

品質管理とその偏り。すべての対象語を kana-whisper が正しく読み、文の CER が 0.08 以下のクリップだけを残す。この条件は、ちょうど難しい例を取り除いてしまう。S3 で落ちた 12 万文のうち 8.4 万文は、Irodori 自身が対象語を読み誤ったためだった。S5 はこれらを、対象語をカタカナにした文から合成し直す（書き起こしは漢字のまま）。その後のセットで、まれなままの読みを補った（表 2）。

効果。どのセットも頭打ちを動かした（図 1）。S3 を 10% 入れると、7k ステップで JKYB-mini が 72.3% から 77.2% になった（JSUT の CER は 6.95 から 5.36%）。S7 は、10 文以上補った読みを 53% から 80% に上げ、補わなかった読みは 50% のままだった。S6a と S5 が続いた（91.0%、91.8%）。合成データが 22–31% でも話者の類似度は変わらなかった。CC BY の系統では、学

表 2　本線の合成セット。残存: すべての対象語と文全体の ASR の確認を通ったもの。

セット	テキスト	残存	時間
S3	S1（読み、Wikipedia、一般）	179k（60%）	341
S4	Tatoeba、2–20 文字	21k（54%）	19
S5	S3 の不合格、対象語はカナ	43k（55%）	84
S6a/b	Wikipedia、読みを 300 文に	108k（72%）	215
S7	LLM の例文、まれな読み *	13k（82%）	15
S9	2–8 トークン、長さを指定	31k（69%）	11

*Claude Haiku が作成、同形異音語は Claude Sonnet が確認。

表 3　公開した教師の学習の混合（時間）。NC: CC BY-NC 4.0、BY: CC BY（* 参照の声による）。

ソース	本線	CC BY ライセンス
Emilia（CC BY 版は Emilia-YODAS）	1,531	305 NC / BY
ゲインを変えた複製	227	48
YODAS3	–	556 BY 3.0
合成音声（Irodori-TTS）	828	425 NC / BY*
合計	2,592	1,334

習初期から合成済のセットを投入した。Emilia（NC）の声で合格していた 30.9 万文を、同じテキストと乱数で Emilia-YODAS の声で合成し直した（2,998 人、553 時間）。

3.4　テキスト、トークナイザ、混合

テキストは正規化する（NFKC、。→.、、→,、括弧の削除、実行系がチャンクを空白でつなぐのに合わせて文末の後に空白）。推論では設定ファイルの 124 個の置換規則が同じ変換をする。トークナイザは学習の書き起こしで作った 4,000 ピースの SentencePiece unigram [18] で、8,000 ピースより 15k ステップで正しく読み（65.3% と 63.4%、McNemar $p = 0.031$）、50 トークンのチャンクが長さの上限に収まりやすい。実行系は文の最後の節だけを生成することがあるが、学習の発話で 5 トークン以下は 0.04% しかなく、Irodori は非常に短い文を 2–3 秒に引き延ばす。S9 は 2–8 トークンの文を、長さを指定して（1 モーラ 0.13 秒）合成した。最終的な混合を表 3 に示す。CC BY の混合はスクリプトで全行を元のマニフェストと照合し、Emilia の NC の部分に由来する行（直接にも、合成音声の声としても）がないことを確かめた。

4　教師の学習

レシピ。上流の学習コードを変更せずに使い、データローダだけを差し替えた。英語の 24 層モデルから、テキストの埋め込み表を作り直して始める。AdamW（weight decay 0.1）、学習率 $2 \cdot 10^{-4}$、バッチ 64、目標は 30 秒まで。声のプロンプトは同じ話者の別の発話で、3–10 秒の先頭部分（50%）、発話全体（35%）、2 発話（15%）とした。RTX 5090 1 枚で毎秒 2.5 ステップで、本線の教師の 70 万ステップに 76 時間かかった。

ステップではなくデータ。本線の教師は 3 回頭打ちになり（70–72%、83.5–85%、87.5–88%）、どれも新しい合成セットが入って初めて抜けた（図 1）。検証損失はこの改善を示さず、JKYB-mini が 5 pt 上がった 93k と 100k のステップで同じ値だった。最後の cosine 減

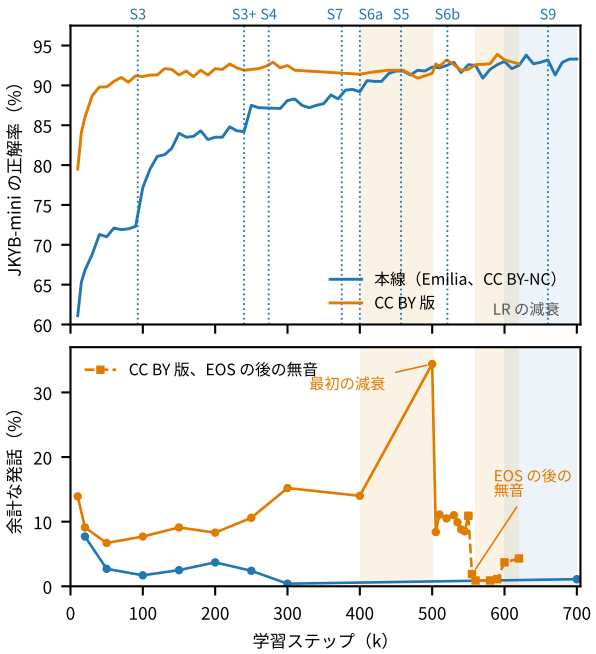


図 1　学習中の教師（CFG 2.0）。上: 読みの正答率は、ステップを重ねたときではなく、新しい合成データが入ったときに上がる。下: 文の後に余計な発話がある文の割合。CC BY 版では、データの掃除でも減衰でも消えず、EOS の後のフレームを教えると消えた。点線: 本線に合成セットが入った時点（表 2、S3+ は S3 の増量）。網掛け: 学習率の減衰。

衰（600k→660k）で JKYB-mini が 0.6 pt、青空文庫が 4.6 pt 上がった（JSUT の CER は 2.86 から 2.40%）。最初から合成データを使った CC BY 版の教師は、35k ステップで 90% に達した。

4.1　発話の終わり方

短いチャンク。172 個の短い文で、660k の本線の教師は 58 文の後に余計な発話を加え、22 文で止まらなかった（CER 28%）。S9 を時間で 1% 混ぜた短文の段（40k ステップ、学習率を上げ直して減衰）で、5k ステップのうちにどちらも直った（1 文と 1 文、CER 4.8%）。

EOS の後のフレーム。CC BY 版の教師は、JKYB-mini の文の 7–15% の後にフィラー（「うん」「えー」）を加えていた。本線の 3–5 倍で、最初の減衰で 34% に増えた。データでの対策は、どれも 7–11% 付近で止まった。YODAS3 のクリップの終わりの切り詰め、YODAS3 の ASR での再チェック、フィラーの除去、YODAS3 そのものの除去でさえそうだった（7.1%、話者の類似度は 0.545 から 0.500 に低下）。EOS の後のフレームを生成しないと、8.8% が 3.3% になった。フィラーの大半は、実行系が足す 5 フレームの中にあった。上流の学習は最後の発話フレームより後で損失をマスクするので、このフレームは一度も学習されない。そこで、すべての完結した目標の後にデジタル無音（ゼロを符号化した Mimi の潜在表現）を 6 フレーム足し、フローの損失をかけた。EOS の目標は発話の終わりのままとする。10k ステップのうちに、余計な発話は 10.9% から 0.9%（本線は 1.1%）、文の CER は 3.6–3.9% から 1.9%、短文の CER は 11.8% から 5.2%

になり、EOS の損失も速度も変わらなかった。続く減衰の後半では、今度は EOS の前にフィラーが戻った（620k で 4.3%）ので、教師には 580k のチェックポイントを使う。

5 蒸留

ガイダンス。CFG なしでは、教師は 1.2 pt 読みが悪く、止まらない文が増え、3.9 LU 小さかった。スケールは 2.0 が最もよく読んだ（93.0%、2.5 では 90.5%）。実行系に CFG がないので、24 層の教師の複製に、凍結した教師のガイダンス後の状態 $z_{\varnothing} + 2(z_c - z_{\varnothing})$ を学ばせる（トランスフォーマーの出力の MSE、ヘッドは凍結、50k ステップ）。結果はガイダンス付きの教師より少しよく読み、`japanese_24l` として公開した。

深さ。6 層の生徒は上流の深さの蒸留に従う。教師の 0, 1, 2, 21, 22, 23 層から始め（上流は外側の層が最良の初期値と報告している）、ガイダンス後の状態を学ぶ（本線は 42k + 120k ステップ、CC BY 版は 160k）。JKYB の全文で生徒は教師を上回る。本線は 94.15 / 94.73% に対して教師 92.97 / 93.68%、CC BY 版は 93.93 / 93.96% に対して 92.82 / 93.82%（プロンプトは交代 / jvs001、元のデコーダ）で、上流の英語の生徒でも同じことが起きている（WER 0.76% と 0.82%）。止まらない文は多い（13,536 文中 43 文、教師は 6 文）。bfloat16 の 6 層モデルは、CPU 1 スレッドで実時間の 4.4 倍で動く（24 層は 1.4 倍）。

公開時の EOS の後のフレーム数。クリップの終わりを音量で調べると、24 層の CC BY 版では、短い終わりの音の半分が EOS の後にあった（クリップの 10.1%、鳴ったまま切れるもの 2.5%）。3 フレームにすると 7.9%、切れるもの 0.7% になる（0 フレームでは 5.9% だが 16% が切れる）ので、設定を 3 とした。6 層の音は EOS の前にあり（どの設定でも 9.4–9.8%）、試聴でも気にならなかったので既定のままとした。

6 デコーダの微調整

なぜ必要か。JVS [27] の読み上げ全体を Mimi に通すと、かな CER は 3.16% から 5.45% に上がる。増えるのは主に調音位置の変わる子音（キ → チ、ガ → ダ）である。子音の分類器は潜在表現から 94.1% を当てるが、デコードした音声からは 92.0% で、情報を失うのはデコーダである。そこでデコード側（1,030 万パラメータ）だけを学習する。エンコーダ、潜在表現、言語モデル、声のプロンプトはそのままで、実行系は新しいデコーダを同じ重みファイルから読む。

本線。損失は多重解像度のメル、MPD [19] と MS-STFT [20] の識別器、アップサンプリングのストライドの周波数（200 Hz と 1.2 kHz の倍数）に立つ音に対する、バッチで平均したスペクトルの損失である。データは合成音声 182 時間と高ビットレートの Emilia 60 時間とした。指標はすべて改善したが、試聴では 2 つのデコーダが、子音の金属的な音と、ピッチに同期した高域のために却下された。4 kHz より上で、録音には倍音がある所に雑音を出していた。最後の 10k ステップでこの帯域を元のデコーダの出力に合わせると（*keep4k*）、耳での問題が消え、改善は保たれた（表 4）。

高域。研究用のブランチで、4 kHz より上をスタジオ録音 [21, 22] に近づける学習をした。指標のうち試聴の判定すべてと一致したのは、全ファイルに 40 Hz のハイパスをかけた UTMOSv2 [23] だけだった（UTMOS22 [24] は順位相関 −0.86、ViSQOL [25] は却下されたデコーダを 1 位にした）が、それでも耳で聞こえた機械的な音は測れなかった。F0 ヘッドによる倍音の励振は聴感が悪く、推論コードの追加も要る。デコーダを広げても変わらない。順位は学習データ自体の予測 MOS で決まり、異なるレシピの run の平均 [26] が最良だったが、NC と継承条件付きのデータを使う。

表 4 JVS の再構成（10 話者 × 100 文）でのデコーダ。UTMOSv2 は keep4k との差。

デコーダ	CER	類似度	UTMOSv2	データ
録音	3.34	–	+0.400	
元の Mimi	5.44	0.698	−0.036	
keep4k（本線の公開版）	4.70	0.779	0	NC
最良の平均（研究用）	4.74	0.784	+0.397	NC、SA
CC BY（`M2CH2_soup4`）	4.69	0.805	+0.383	CC BY

CC BY 版のデコーダ。使えるのは元の Mimi、YODAS3、CC BY の声の合成音声だけである。YODAS3 のクリップを、15 kHz まで音があり DNSMOS の高い動画から 24 kHz で切り出し直し（9 万クリップ、234 時間）。クリップの選択は、UTMOSv2 の順位は効き、倍音の強さは効かなかった。土台は元の Mimi から YODAS3 164 時間と合成音声 116 時間で 70k ステップ（識別器も一から）学習し、その上で帯域の欠けやクリッピングのない UTMOSv2 の上位のクリップ（7–14 時間）で高域を学ぶ 10k ステップの run を 4 本回して平均した。試聴で合成音声と分かった YODAS3 の動画 2 本は除いた。結果は再構成で NC の最良のデコーダと並び、TTS では少し上回る（元の Mimi より UTMOSv2 +0.35–0.42、話者の類似度 0.55→0.65）。試聴では NC の最良のデコーダと区別がつかなかった。

7 公開したモデル

公開したモデルを表 5 に示す。生成した音声を kana-whisper で書き起こして評価する。JKYB-Parakeet [28, 29]（対象語に印を付けた 13,536 文。プロンプトは JVS の 4 話者の交代、または jvs001）、その 1,500 文の部分集合 JKYB-mini、合成に使っていない作品の青空文庫のルビ 1,000 語、JSUT [30] の 1,000 文、JVS の 10 話者のゼロショットのクローン（かな CER と、その話者が同じ文を読んだ録音との ECAPA の類似度）、短い文 172 個である。JVS と JSUT は学習に使わない。公開したファイルを公式パッケージで CPU で読み込んでも、揺れの範囲で同じになる（本線の `japanese`: JKYB-mini 95.3%、JSUT 2.15%、JVS 1.70% / 0.575）。

専用のデコーダで、半分のデータの CC BY 版も本線に並ぶ。どちらの 6 層も JKYB の約 5% を読み誤り、多くはまれな読みと熟字訓である。

8 議論

効いたこと。第一に網羅性。モデルは十分な回数聞いた読みだけを覚える。読みの正しい TTS モデルの合

表 5 公開したモデル（GPU での評価。L: 層、教師は CFG 2.0）。JKYB: 全文、プロンプトは交代 / jvs001。CER は%。短文: 止まらない / 余計な発話（172 文中）。赤: 暫定。

モデル	JKYB	mini	青空	JSUT	JVS	/ 類似度	短文
本線（*CC BY-NC*）、デコーダ *keep4k*							
6L	94.75 / 94.84	95.1	71.3	2.28	2.32 / .577		0 / 1
24L	94.32 / 94.49	94.5	71.2	2.28	2.13 / .586		0 / 1
CC BY 版、*CC BY* のデコーダ							
6L	94.77 / TBD	94.9	70.7	2.14	2.18 / .651	0 / TBD	
24L	TBD	TBD	TBD	TBD	TBD		TBD
元の *Mimi* のデコーダ							
本線 6L	94.15 / 94.73	93.8	70.0	2.39	2.58 / .536		0 / 1
CC BY 6L	93.93 / 93.96	94.3	69.0	2.40	2.47 / .560		0 / 1
CC BY 24L	93.34 / 94.08	93.5	68.5	2.48	2.67 / .547		0 / 0
本線の教師	92.97 / 93.68	93.3	69.4	2.66	3.05 / –		1 / 2
CC BY の教師	92.82 / 93.82	92.7	67.9	2.58	2.45 / .546		0 / –

成音声を ASR で確かめたものが最も安くそれを補う。ただし確認が難しい読みを捨ててはいけない。第二に実行系がすることを学習させる。EOS の後のフレーム、短いチャンク、CFG がないことは、それぞれ教えるか蒸留する必要があった。第三にデコーダは指標だけでは決められない。却下したデコーダはどれも、すべての指標を改善していた。

限界。スコアは ASR に基づき、乱数は 1 通りで、JKYB-mini は評価ごとに約 ±0.5–1 pt 動く。合成データの割合を制御した比較はしていない。合成音声には Irodori の読みと話し方が乗る。生徒は教師より少し止まらない文が多く、CC BY 版のクリップの 8–10% は短く静かな音で終わる。

9 おわりに

日本語の Pocket TTS は、実行系を変えずに作れる。改善の大半はデータから来た。ASR で再チェックした Web の音声、揃えた音量、まれな読みを補う合成音声である。実行系が EOS の後に生成するフレームを教えると文末のフィラーが消え、蒸留で教師よりよく読む 6 層のモデルができ、CC BY の音声で微調整したデコーダで、CC BY 版は Emilia を使った版に並んだ。

謝辞

Pocket TTS と学習コードを公開した Kyutai と、Emilia、YODAS3、Irodori-TTS、JKYB と Parakeet 版、kana-whisper、JSUT、JVS、Hi-Fi-CAPTAIN、JVNV、UTMOSv2、青空文庫、Wikipedia、Tatoeba、EDRDG の辞書の作成者に感謝する。

参考文献

[1] M. Orsini, S. Rouard, G. De Marmiesse, V. Volhejn, N. Zeghidour, A. Défossez. Pocket TTS. https://github.com/kyutai-labs/pocket-tts, 2026.

[2] S. Rouard, M. Orsini, A. Roebel, N. Zeghidour, A. Défossez. Continuous audio language models. *ICLR*, 2026.

[3] T. Li, Y. Tian, H. Li, M. Deng, K. He. Autoregressive image generation without vector quantization. *NeurIPS*, 2024.

[4] N. M. Boffi, M. S. Albergo, E. Vanden-Eijnden. How to build a consistency model: Learning flow maps via self-distillation. *NeurIPS*, 2025.

[5] J. Ho, T. Salimans. Classifier-free diffusion guidance. arXiv:2207.12598, 2022.

[6] A. Défossez et al. Moshi: a speech-text foundation model for real-time dialogue. arXiv:2410.00037, 2024.

[7] H. He et al. Emilia: An extensive, multilingual, and diverse speech dataset for large-scale speech generation. *SLT*, 2024.

[8] H. He et al. Emilia: A large-scale, extensive, multilingual, and diverse dataset for speech generation. arXiv:2501.15907, 2025.

[9] B. Desplanques, J. Thienpondt, K. Demuynck. ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in TDNN based speaker verification. *Interspeech*, 2020.

[10] C. K. A. Reddy, V. Gopal, R. Cutler. DNSMOS P.835: A non-intrusive perceptual objective speech quality metric to evaluate noise suppressors. *ICASSP*, 2022.

[11] X. Li et al. YODAS: YouTube-oriented dataset for audio and speech. *ASRU*, 2023.

[12] W. Chen, S. Takamichi, S. Shiota, S. Fukayama, S. Cornell, S. Watanabe. YODAS v3: Over 1 million hours of high-bandwidth, stereophonic, multilingual speech. *Interspeech*, 2026.

[13] Silero Team. Silero VAD. https://github.com/snakers4/silero-vad.

[14] A. Radford et al. Robust speech recognition via large-scale weak supervision. *ICML*, 2023.

[15] SB Intuitions. `sbintuitions/kana-whisper`. Hugging Face.

[16] Claude, 森琢磨. フローマッチング TTS に漢字の読みを教える. テクニカルレポート, 2026.

[17] J. Breen. JMdict: a Japanese-multilingual dictionary. *COLING Workshop on Multilingual Linguistic Resources*, 2004.

[18] T. Kudo, J. Richardson. SentencePiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. *EMNLP (demo)*, 2018.

[19] J. Kong, J. Kim, J. Bae. HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis. *NeurIPS*, 2020.

[20] A. Défossez, J. Copet, G. Synnaeve, Y. Adi. High fidelity neural audio compression. *TMLR*, 2023.

[21] NICT. Hi-Fi-CAPTAIN corpus. https://ast-astrec.nict.go.jp/en/release/hi-fi-captain/.

[22] D. Xin et al. JVNV: A corpus of Japanese emotional speech with verbal content and nonverbal expressions. *IEEE Access*, 2024.

[23] K. Baba, W. Nakata, Y. Saito, H. Saruwatari. The T05 system for the VoiceMOS Challenge 2024. *SLT*, 2024.

[24] T. Saeki et al. UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022. *Interspeech*, 2022.

[25] M. Chinen et al. ViSQOL v3: An open source production ready objective speech and audio metric. *QoMEX*, 2020.

[26] M. Wortsman et al. Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. *ICML*, 2022.

[27] S. Takamichi et al. JVS corpus: free Japanese multi-speaker voice corpus. arXiv:1908.06248, 2019.

[28] SB Intuitions. Joyo Kanji Yomi Benchmark. https://github.com/sbintuitions/Joyo-Kanji-Yomi-Benchmark.

[29] Parakeet Inc. Joyo Kanji Yomi Benchmark, Parakeet Edition. https://github.com/Parakeet-Inc/Joyo-Kanji-Yomi-Benchmark-Parakeet-Edition.

[30] R. Sonobe, S. Takamichi, H. Saruwatari. JSUT corpus: free large-scale Japanese speech corpus for end-to-end speech synthesis. arXiv:1711.00354, 2017.